Министерство науки и высшего образования Российской Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«Национальный исследовательский университет ИТМО»
(Университет ИТМО)

Факультет Программной инженерии и компьютерной техники

Образовательная программа Проектирование и разработка систем искусственного интеллекта

Направление подготовки (специальность) 09.04.04 Программная инженерия

О Т Ч Е Т
о Научно-исследовательской работе

Тема задания: Инженерия знаний и агентные системы в управлении образовательными процессами
Обучающийся: Константинов Александр Александрович, P4244

Руководитель практики от университета: Авдюшина Анна Евгеньевна, преподаватель факультета программной инженерии и компьютерной техники

Дата: 15 января 2026

Санкт-Петербург
2026

СОДЕРЖАНИЕ

Введение 2

1 Описание выполнения этапов практики 4

1.1 Подготовка датасета для тестирования качества разметки 4

1.2 Тестирование системы и сравнение различных методов конвертации 5

1.3 Анализ результатов и выбор оптимального подхода 7

Заключение 12

Список источников литературы 13

Приложение А 14

Приложение Б 16

ВВЕДЕНИЕ

Современные образовательные технологии активно развиваются в направлении автоматизации обработки учебных материалов. Платформа KEEL (Knowledge Engineering for Educators Layer) представляет собой многоагентную систему, предназначенную для помощи преподавателям в организации и взаимодействии с фрагментированным учебным контентом. Основная задача платформы заключается в автоматическом построении структурированных карт знаний на основе разнородных образовательных материалов.

Ключевой проблемой при работе с учебными документами является потеря их иерархической структуры в процессе парсинга и конвертации. Учебные материалы поступают в систему в различных форматах — PDF-файлы лекций, презентации PowerPoint, текстовые документы. При их обработке традиционными методами извлечения текста теряется информация о заголовках, разделах и подразделах, что критически важно для восстановления логической структуры курса.

Целью данной работы является исследование и выбор оптимального метода конвертации документов для компонента Structure Agent платформы KEEL. Основным критерием эффективности выбрана метрика полноты извлечения заголовков (Recall), поскольку именно заголовки служат ключевыми маркерами для реконструкции структуры учебного материала.

Для достижения поставленной цели определены следующие исследовательские задачи:

1. Создание эталонного датасета учебных презентаций с ручной разметкой заголовков для объективной оценки качества различных методов извлечения структуры.

2. Реализация и тестирование различных подходов к конвертации документов, включая rule-based методы, гибридные пайплайны и современные визуальные языковые модели.

3. Проведение сравнительного анализа эффективности методов на основе метрик качества.

Исследование выполнено в три последовательные этапа. Первый этап включает формирование датасета из 169 реальных учебных презентаций с детальной ручной разметкой заголовков. Второй этап посвящен реализации и тестированию трех различных подходов к обработке документов. Заключительный этап содержит анализ полученных результатов и выработку практических рекомендаций.

1 ОПИСАНИЕ ВЫПОЛНЕНИЯ ЭТАПОВ ПРАКТИКИ

1.1 Подготовка датасета для тестирования качества разметки

Основной задачей данного этапа являлось создание эталонного набора данных для объективной оценки качества извлечения структуры из учебных материалов. Поскольку платформа KEEL предназначена для работы с разнородными образовательными документами, было принято решение сосредоточиться на наиболее сложных для обработки форматах - презентациях в форматах PDF и PPTX.

Выбор презентаций в качестве основного типа документов обусловлен их особой структурной сложностью. В отличие от текстовых документов с линейной структурой, презентации содержат слайды с произвольным расположением элементов, различными размерами шрифтов и сложной визуальной компоновкой. Именно эти характеристики делают извлечение заголовков из презентаций наиболее трудной задачей для автоматических систем обработки.

Для формирования датасета был собран корпус из 169 реальных учебных презентаций преподавателей ИТМО. Материалы охватывают различные дисциплины и представлены в двух основных форматах: 129 файлов в формате PDF и 40 файлов в формате PPTX.

Процедура создания эталонной разметки выполнялась полностью вручную с применением строгих критериев отбора заголовков. Каждая презентация просматривалась последовательно, слайд за слайдом. Для каждого слайда определялся основной заголовок на основе следующих признаков: наибольший размер шрифта среди текстовых элементов, расположение в верхней части слайда и семантическая роль в качестве названия или темы слайда.

Особое внимание уделялось единообразию критериев разметки. В случаях, когда на слайде присутствовало несколько текстовых элементов с крупным шрифтом, приоритет отдавался тому, который наилучшим образом

отражал содержание слайда. Слайды без явно выраженных заголовков (например, содержащие только изображения или диаграммы) помечались соответствующим образом в разметке.

Результаты ручной разметки были систематизированы и сохранены в структурированном формате CSV. Каждая запись содержит информацию о файле презентации, названии курса, преподавателе и полный список заголовков слайдов.

Структура разметки и примеры записей из датасета представлены в Приложении А.

1.2 Тестирование системы и сравнение различных методов конвертации

Для объективного сравнения эффективности различных подходов к извлечению структуры из презентаций была спроектирована модульная архитектура системы обработки файлов. В основе архитектуры лежит абстрактный базовый класс BaseFileProcessor, который определяет единый интерфейс *process* для всех обработчиков.

В рамках исследования были реализованы и протестированы три принципиально различных группы методов обработки презентаций. **Native** методы работают напрямую с исходными форматами файлов. К этой группе относится MarkItDownPPTXProcessor и DoclingProcessor, которые используют библиотеки MarkItDown [1] и Docling [2] для прямого извлечения текста из PPTX файлов без промежуточных конвертаций **OCR**, который основан на оптическом распознавании символов. Сюда входят MistralPDFProcessor, который использует Mistral API [3], и DoclingProcessor для работы с PDF файлами и PPTXViaMistralOCRProcessor для обработки PPTX через предварительную конвертацию в PDF с последующим применением OCR. Для обеспечения корректной работы с PPTX файлами был создан промежуточный класс BaseLibreOfficeProcessor, который инкапсулирует логику взаимодействия с LibreOffice [4] для конвертации презентаций PPTX в PDF формат. **VLM-подход** представляет собой решение, использующее

возможности мультимодальных языковых моделей для визуального анализа страниц документов. Основным представителем этой группы является VLMProcessor, реализующий запросы к модели Gemini 2.5 Flash [5]. Данный процессор переводит страницы документа в изображения и передает их в визуальную языковую модель для извлечения текста и структуры.

В качестве эталонного решения для оценки качества был выбрана VLM модель Gemini 2.5 Flash. Выбор обусловлен тем, что визуальные языковые модели способны анализировать не только текстовое содержимое, но и визуальную структуру документа — размеры шрифтов, расположение элементов, иерархию заголовков. Это позволяет им более точно определять, какие элементы являются заголовками слайдов, что критически важно для корректного извлечения структуры презентаций.

Для количественной оценки качества извлечения заголовков была разработана система метрик, основанная на сравнении с эталонной ручной разметкой. В качестве основной метрики была выбрана **Recall**, поскольку пропуск даже одного заголовка приводит к потере целого смыслового блока в структуре документа. Дополнительно рассчитывались метрики **Precision** и **F1-score** для комплексной оценки качества.

Ключевой особенностью разработанной методологии оценки стало внедрение алгоритма нечеткого сравнения заголовков (**Fuzzy Matching**). Такой подход позволил проводить прямое сравнение строк, включающих в себя заголовки, без занижения результатов из-за возможных артефактов OCR, различий в форматировании и вариативности представления одного и того же заголовка в разных системах. Алгоритм включает этапы нормализации текста (удаление нумерации, приведение к нижнему регистру, очистка спецсимволов) и последующее сравнение с использованием алгоритма Левенштейна с порогом схожести 0.85.

Для автоматизации процесса тестирования был разработан класс HeaderBenchmark, который обеспечивает воспроизводимость экспериментов и возможность быстрого сравнения новых методов обработки. Бенчмарк

автоматически применяет все доступные процессоры к тестовому датасету, рассчитывает метрики качества и формирует сводные отчеты о производительности каждого подхода.

Детальная реализация всех процессоров обработки файлов и алгоритмов сравнения представлена в Приложении Б.

1.3 Анализ результатов и выбор оптимального подхода

На основе проведенного тестирования всех реализованных процессоров была выполнена комплексная оценка их эффективности. Результаты экспериментов позволили выявить ключевые закономерности в работе различных подходов и определить оптимальную стратегию обработки учебных материалов.

Анализ соотношения скорости обработки и качества извлечения заголовков выявил четкую кластеризацию методов по их характеристикам. Диаграмма рассеяния (Рисунок 1) демонстрирует, что процессоры распределились по трем основным группам в зависимости от времени выполнения и достигаемого качества F1-Score.

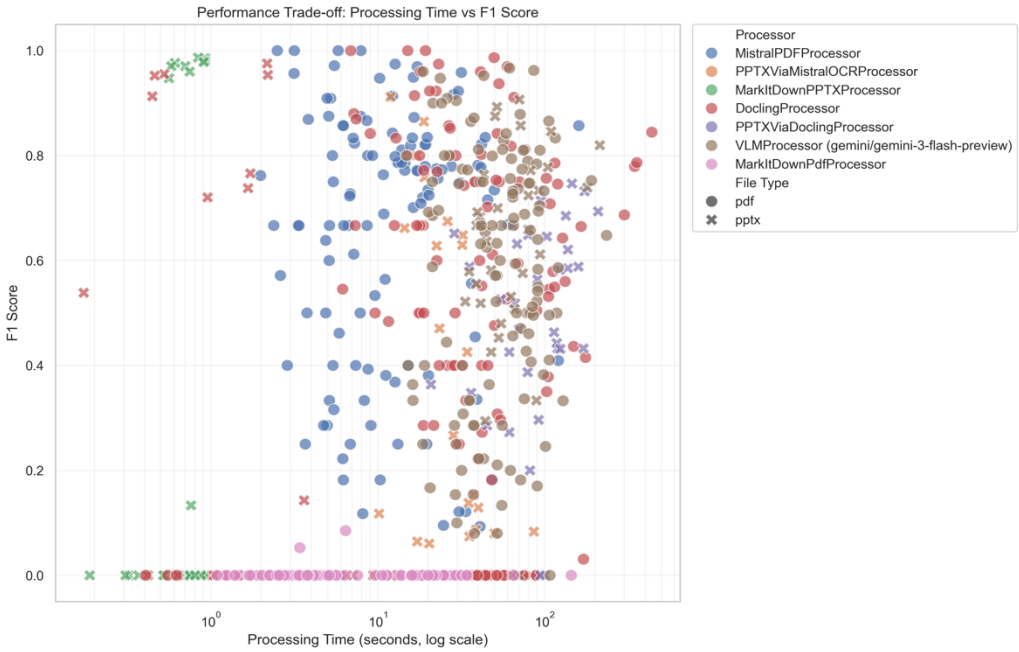

Рисунок 1 — Сравнение процессоров по скорости и качеству

Процессоры семейства MarkItDown показали наименьшее время обработки — менее одной секунды на документ, однако их качество характеризуется крайней нестабильностью. Значения F1-Score варьируются от полного отказа (0.0) до идеального результата (1.0), что делает эти методы непредсказуемыми для практического применения. Противоположную позицию занимает VLMProcessor, который требует значительных временных затрат (от 10 до 100 секунд), но обеспечивает стабильно высокое качество с F1-Score превышающим 0.8 в большинстве случаев.

Промежуточное положение занимают процессоры MistralPDFProcessor и DoclingProcessor, которые демонстрируют разумный компромисс между скоростью и качеством обработки PDF файлов. Время их работы составляет от 15 до 60 секунд, при этом качество извлечения заголовков остается на приемлемом уровне.

Особое внимание было уделено анализу полноты извлечения заголовков для различных типов файлов. Сравнительный анализ метрики Recall (Рисунок 2) выявил критическую проблему при обработке PPTX-презентаций. VLMProcessor продемонстрировал превосходные результаты для обоих форматов, достигая значений Recall выше 0.85 как для PDF, так и для PPTX файлов. Это подтверждает эффективность визуального анализа документов для извлечения структурной информации.

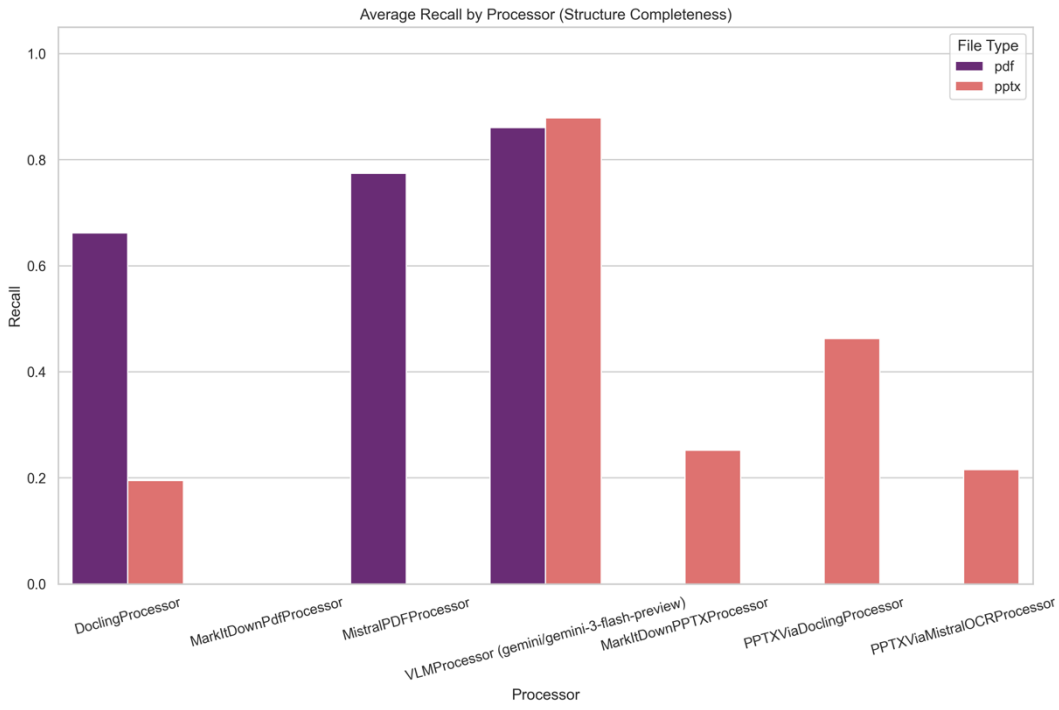

Рисунок 2 — Сравнение полноты извлечения заголовков

MistralPDFProcessor показал высокую эффективность при работе с PDF-документами, достигая Recall около 0.75, что делает его привлекательным решением для этого формата. DoclingProcessor продемонстрировал умеренные результаты для PDF-файлов, но значительно уступил при обработке PPTX-презентаций.

Наиболее критичной оказалась производительность MarkItDown при работе с PPTX-файлами. Согласно результатам тестирования, MarkItDownPPTXProcessor показал практически нулевой Recall для презентаций в нативном формате, что свидетельствует о фундаментальных ограничениях подхода прямого парсинга XML-структуры PPTX-файлов.

Анализ стабильности работы процессоров на основе распределения F1-Score (Рисунок 3) подтвердил выводы о надежности различных подходов. VLMProcessor характеризуется наиболее компактным распределением результатов с высокой медианой около 0.9, что указывает на его предсказуемость и стабильность. Напротив, процессоры MarkItDown демонстрируют чрезвычайно широкий разброс значений, подтверждая их ненадежность для практического использования.

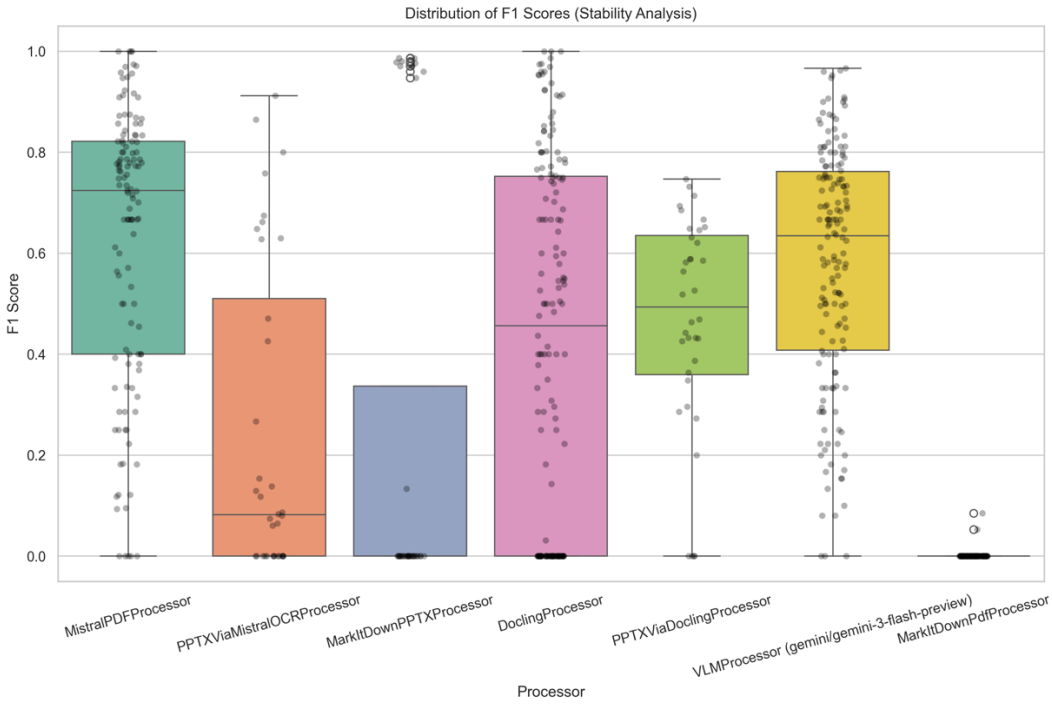

Рисунок 3 — Распределение F1-Score

Детальный анализ причин неэффективности MarkItDown при обработке PPTX-файлов показал, что в 72% случаев процессор возвращал F1-Score равный нулю, что означает полную неспособность извлечь какие-либо заголовки. Это связано с особенностями внутренней структуры PPTX-файлов, где текстовые элементы могут быть представлены в различных XML-узлах без явной иерархии, что затрудняет автоматическое определение заголовков.

Гибридный подход, реализованный в PPTXViaMistralOCRProcessor, продемонстрировал значительно лучшие результаты для PPTX-файлов. Предварительная конвертация презентаций в PDF-формат с сохранением визуального представления позволяет применить эффективные OCR-методы для извлечения текста с учетом его пространственного расположения и размеров шрифтов.

На основе проведенного анализа было принято решение об использовании дифференцированного подхода к обработке различных типов файлов. Для PDF-презентаций оптимальным выбором является MistralPDFProcessor, который обеспечивает высокую полноту извлечения

заголовков при разумном времени обработки. Для PPTX-презентаций рекомендуется использование PPTXViaMistralOCRProcessor, который через гибридную схему конвертации достигает качества, сопоставимого с VLM-подходами, при значительно меньших вычислительных затратах.

VLMProcessor, несмотря на свои высокие показатели качества, рекомендуется использовать в качестве эталонного решения для особо сложных случаев или для валидации результатов других процессоров, когда высокая точность критична и временные затраты не являются ограничивающим фактором.

ЗАКЛЮЧЕНИЕ

В ходе выполнения данной научно-исследовательской работы была решена задача сравнительного анализа методов извлечения структурных сигналов из учебных презентаций для платформы KEEL, основной целью которой являлось определение оптимального подхода к автоматическому извлечению заголовков слайдов. Для достижения поставленной цели был выполнен комплекс работ, включающий создание уникального датасета из 169 презентаций с ручной разметкой и реализацию в рамках единой модульной архитектуры трех групп методов: native-подходов, OCR-методов и VLM-подходов. Проведенное тестирование показало, что, несмотря на высокое качество VLM-процессора на базе Gemini 2.5 Flash (Recall > 90%), для практического внедрения был выбран дифференцированный подход — использование MistralPDFProcessor для PDF и PPTXViaMistralOCRProcessor для PPTX-файлов, что обеспечивает оптимальный баланс между точностью и скоростью обработки. Разработанная методология оценки с применением нечеткого сравнения заголовков подтвердила объективность полученных метрик, а результаты исследования имеют практическую значимость для развития платформы KEEL, так как выбранные решения полностью готовы к интеграции в продуктивную среду для автоматизации структурирования учебного контента.

СПИСОК ИСТОЧНИКОВ ЛИТЕРАТУРЫ

1. MarkItDown [Электронный ресурс]: инструмент для конвертации файлов в Markdown / Microsoft // GitHub. — Режим доступа: https://github.com/microsoft/markitdown (дата обращения: 18.01.2026).

2. Docling [Электронный ресурс]: документация библиотеки. — Режим доступа: https://docling-project.github.io/docling/ (дата обращения: 18.01.2026).

3. Mistral AI Basic OCR [Электронный ресурс] // Документация Mistral AI. — Режим доступа: https://docs.mistral.ai/capabilities/document_ai/basic_ocr (дата обращения: 18.01.2026).

4. LibreOffice [Электронный ресурс]: свободный офисный пакет. — Режим доступа: https://ru.libreoffice.org (дата обращения: 18.01.2026).

5. Google Gemini [Электронный ресурс]: нейросетевая модель. — Режим доступа: https://gemini.google.com (дата обращения: 18.01.2026).

Приложение А

Датасет организован в виде CSV-файла со следующими полями:

1. **Name**: Фамилия и инициалы преподавателя
2. **Courses**: Код курса или название дисциплины
3. **Title**: Название конкретной лекции или темы
4. **Filenames**: Имя файла презентации
5. **Headers**: Список заголовков слайдов в формате строки

Name	Courses	Title	Filenames	Headers
Солодкая М.А	AI_system_Solodkaya	История возникновения ИИ	Лекция 1. История ИИ.pdf	"Наш план", "Что такое AI?", "Философия ИИ", "Разработка систем ИИ", "Что такое ML?", "Немного о данных"
Солодкая М.А	AI_system_Solodkaya	История возникновения ИИ	Лекция 1. История ИИ.pdf	"Вспомним", "Смещение (bias)", "Смещение (bias). Пример", "Градиент", "Пример", "Для чего нужен градиент..."

Таблица 1 – Пример разметки.

При создании эталонной разметки применялись следующие правила:

1. Выбор текста с наибольшим размером шрифта на слайде
2. Приоритет элементам, расположенным в верхней части слайда
3. Семантическая значимость как заголовка или названия темы
4. Исключение технических элементов (номера слайдов, колонтитулы)
5. Сохранение оригинального форматирования и пунктуации заголовков

Приложение Б

Код реализации процессоров и бенчмарка

Ссылка на репозиторий с исходным кодом:

https://github.com/sanchous1000/NIR_code/tree/main

Структура репозитория:

– **file_processor/** - основной пакет, реализующий логику конвертации и парсинга документов из PPTX и PDF в Markdown.

– **benchmarking/** - подсистема для проведения сравнительного анализа и оценки качества.